



République Algérienne Démocratique et Populaire Ministère de l'Enseignement
Supérieur et de la Recherche Scientifique

Université de sciences et de technologies Houari Boumediène

Faculté Mathématiques
Département De Recherche Opérationnelle

Mémoire

En vue de l'obtention du Diplôme de Licence en Recherche Opérationnelle

Thème

**Application des réseaux de neurones artificiels pour
la prévision de l'énergie solaire**

Encadré par

- Dr. SOUKEUR El Hussein iz El Islam

Réalisé par

- SAIM Sarah
- TALEB Nesrine

Soutenu le : **17/05/2023**

Remerciements

Nous tenons à exprimer nos remerciements et notre reconnaissance infinies à Dieu, le Tout-Puissant, qui nous a accordé le courage, la détermination et la persévérance nécessaires pour mener à bien ce travail présent.

On remercie chaleureusement notre encadrant : **Dr SOUKEUR El Hussein iz El Islam** pour avoir accepté de superviser notre mémoire, pour son accompagnement, conseils avisés et soutien tout au long de ce projet.

Nous souhaitons exprimer notre profonde gratitude envers nos parents qui ont été à nos côtés pour nous encourager, ainsi qu'envers nos frères et sœurs, amis, proches et toute personne qui nous a apporté son aide et ses encouragements durant la réalisation de ce mémoire, que ce soit de près ou de loin.

Enfin, nous tenons également à nous remercier nous-mêmes pour chaque effort fourni, ainsi que pour avoir surmonté toutes les pressions et obstacles rencontrés.

Résumé

Les Réseaux de Neurones Artificiels (RNA) sont des outils très puissants utilisés dans le domaine de l'apprentissage automatique. Ils sont de nos jours souvent appliqués pour prévoir des séries temporelles en apprenant à partir de données passées pour prédire les valeurs futures de la série chronologique. L'objectif de notre travail est de proposer un modèle RNA pour la prévision journalière du rayonnement solaire. De ce fait, le modèle ainsi développé, a été testé pour une station de la ville d'Oran au nord-ouest Algérien qui est une zone côtière caractérisée par un climat méditerranéen semi-aride. En outre, une série de données d'une dizaine d'années entre 2010 et 2018 ont été utilisées pour l'entraînement et l'implémentation du modèle développé, et le test est effectué par rapport à l'année 2019. Les résultats obtenus montrent que le modèle développé donne une bonne performance.

Mots clefs : Réseaux Neuronaux Artificiels ; Perceptrons Multi Couches ; Séries Temporelles ; MERRA-2; Energie Renouvelable; Intelligence Artificielle.

Abstract

Artificial Neural Networks (ANN) are powerful tools used in the field of machine learning. Nowadays, they are often applied to forecast time series by learning from past data to predict future values of the chronological series. The objective of our work is to propose an ANN model for the daily prediction of solar radiation. Therefore, the developed model has been tested for a station in the city of Oran in northwestern Algeria, which is a coastal zone characterized by a semi-arid Mediterranean climate. Moreover, a data series of about ten years between 2010 and 2018 were used for training and implementing the developed model, and the test is performed with respect to the year 2019. The obtained results show that the developed model gives good performance.

Keywords: Artificial Neural Network; Multi-Layer Perceptron; Time Series Models; MERRA-2; Renewable energies; Artificial Intelligence

ملخص

الشبكات العصبية الاصطناعية هي أدوات قوية جدا تستخدم في مجال التعلم الآلي، يتم تطبيقها في الوقت الحالي بشكل متكرر لتوقع السلاسل الزمنية عن طريق التعلم من البيانات السابقة لتوقع القيم المستقبلية للسلسلة الزمنية. هدف للتنبؤ بالاشعاع الشمسي اليومي لذلك تم اختبار النموذج الذي تم تطويره لمحطة في مدينة RNA عملنا هو تقديم نموذج وهران شمال غرب الجزائر التي و تعد منطقة ساحلية تتميز بمناخ شبع جاف من البحر الأبيض المتوسط.بالاضافة إلى ذلك ، تم استخدام سلسلة بيانات لعشر سنوات بين 2010 و 2018 لتدريب و تنفيذ النموذج المطور، و تم اجراء الاختبار بالنسبة لعام 2019.تظهر النتائج المتحصل عليها أن النموذج المطور يعطي أداء جيد

الكلمات المفتاحية: الشبكة العصبية الاصطناعية؛ الشبكة العصبية متعددة الطبقات؛ نماذج السلاسل الزمنية؛ MERRA-2؛ الطاقات المتجددة؛ الذكاء الاصطناعي.

Table des matières

Remerciements	2
Résumé	3
INTRODUCTION GENERALE	11
Chapitre 1 : Réseaux de neurones artificiels.	14
1.1 Introduction et historique.....	14
1.1.1 Introduction	14
1.1.2 Historique	14
1.2 L'intérêt de l'utilisation des réseaux de neurones artificiels	15
1.3 Notions de base sur les réseaux de neurones artificiels	15
1.3.1 Différents neurones	15
1.3.1.1 : Neurone biologique	16
1.3.1.2 Neurone formel (artificiel).....	17
1.3.1.2.1 Perceptron simple.....	18
1.3.1.2.2 Le Perceptron Multicouche (PMC)	19
1.3.2 Fonctions d'activation.....	19
1.3.2.1 Propriétés de la Fonction d'activation :	21
1.3.3 Les réseaux de neurones	21
1.3.3.1 Définition.....	21
1.3.3.2 Typologie des réseaux de neurones artificiels	22
1.3.3.2.1 Réseau de neurones non bouclé	22
1.3.3.2.2 Réseau de neurones bouclé.....	23
1.4 Apprentissage des réseaux de neurones	24
1.4.1 Le type d'apprentissage des réseaux de neurones artificiels	24
1.4.1.1 Apprentissage supervisé.....	24
1.4.1.2 Apprentissage non-supervisé.....	25
1.4.1.3 Apprentissage hybride	26
1.4.2 Règles d'apprentissage.....	26
1.5 L'algorithme de rétro-propagation du gradient de l'erreur	27
1.6 Avantages et inconvénients :.....	29
1.6.1 Avantages	29
1.6.2 Inconvénients	30
Conclusion.....	30
Chapitre 2 : Le perceptron multicouche et la prédiction des séries temporelles	31

2.1 Introduction	31
2.2 Domaines d'application	31
2.3 Formalisme Mathématique	32
2.3.1 Définition.....	32
2.3.2 Classification des séries temporelles	33
2.3.3 Éléments de l'analyse d'une série temporelle	34
2.3.4 Les composantes constitutives d'une série temporelle.....	34
2.4 PMC séries temporelles	35
Conclusion.....	36
Chapitre 3 : Conception et élaboration des modèles de prévision d'énergies renouvelables.	37
3.1 Introduction	37
3.2 Contexte de réalisation	37
3.2.1 Environnement matériel.....	37
3.2.2 Environnement logiciel	38
3.2.2.1 Langage utilisé.....	38
3.2.2.2 Bibliothèques utilisé	38
3.3 Présentation et description des données.....	39
3.3.1 Présentation des données.....	39
3.3.2 Description des données :	39
3.3.2.1 MERRA-2	39
3.4 Les procédures de développements et élaborations des modèles RNA	40
3.4.1 Collection et séparation de la base de données	40
3.4.2 Prétraitements des données.....	41
3.4.3 L'architecture PMC séries temporelles	42
3.4.4 Apprentissage et paramétrage du modèle.....	42
3.4.5 Phase de test.....	43
Chapitre 4 : La prévision journalière de la série chronologique de rayonnement solaire.	44
4.1 Problématique et objectif	44
4.2 Implémentation du modèle RNA	45
4.2.1 Présentation des données.....	45
4.2.2 Collection et séparation de la base de données	46
4.2.3 Prétraitement des données	46
4.2.4 Architecture du modèle RNA	46

4.2.5 Apprentissage et configuration	47
4.2.6 Évaluation de la précision du modèle RNA	47
4.3 Résultats et discussions	48
4.3.1 Paramétrage du modèle RNA	48
4.3.2 Résultats prévisionnels quotidiens et précision	49
Conclusion.....	51
CONCLUSION GENERALE	52
Références bibliographiques	54

Table des figures

Figure 1 - Neurone Biologique	17
Figure 2 - Neurone Artificiel.....	18
Figure 3 - Présentation du réseau de neurones Perceptron multicouches	19
Figure 4 - Un réseau de neurones non bouclés (Perceptron multicouche).....	23
Figure 5 - Forme canonique d'un réseau de neurones bouclés.....	23
Figure 6 - l'apprentissage supervisé.....	25
Figure 7 - l'apprentissage non supervisé	25
Figure 8 - Nombre de passagers (en milliers) dans les transports aériens	33
Figure 9 - Présentation de l'application du PMC à la prévision des séries chronologiques	36
Figure 10 - Une partie des données.....	45
Figure 11 - Séparation de la base de données	46
Figure 12 - Les RMSE en fonction du nombre de couches cachées et du nombre de neurones dans chaque couche cachée (la barre rouge correspond au RMSE le plus faible choisi).....	49
Figure 13 - Courbe chronologique de prédiction de rayonnement solaire SWGDN prédit comparé au SWGDN de MERRA-2 avec RMSE.....	50
Figure 14 - Diagramme de dispersion	51

Liste des tableaux

Tableau 1 - Analogie entre le neurone biologique et le neurone formel.....	18
Tableau 2 - La configuration matériel pour la réalisation de projet.....	37
Tableau 3 - Paramètres de performance utilisés pour l'entraînement du modèle.....	48
Tableau 4 - les performances (statistiques d'erreurs obtenues) pour le modèle ANN pour la formation et la validation.	50

Liste des algorithmes

Algorithme 1 - Algorithme de retro-propagation.....	29
---	----

Liste des abréviations

ANN	Artificial Neural Network
DL	Deep Learning
IA	Intelligence Artificielle
MAE	Mean Absolute Error
MERRA 2	Modern-Era Retrospective analysis for Research and Applications, version 2
ML	Machine Learning
MLP	Multi Layer perceptron
MSE	Mean Squard Error
NASA	National Aeronautics and Space Administration
PIB	Produit Intérieur Brut
PMC	Perceptron Multicouche
RMSE	Root Mean Square Error
RNA	Réseaux de Neurones Artificiels
RO	Recherche Opérationnelle

INTRODUCTION GENERALE

L'émergence de la technologie de l'information a permis le développement de l'ingénierie numérique, discipline qui se trouve entre les mathématiques théoriques et appliquées. Elle utilise des techniques de calcul numérique pour résoudre des problèmes mathématiques complexes et permet de simuler des comportements pour prendre des décisions plus efficaces dans des domaines tels que la gestion des transports et la prévision météorologique.

Le domaine de la science et de la technologie est fortement optimisé par l'utilisation de l'intelligence artificielle, dont les progrès récents ont augmenté sa popularité, notamment en ce qui concerne les concepts d'apprentissage automatique. Grâce à l'Intelligence Artificielle (IA), les machines peuvent apprendre par expérience, ce qui leur permet d'exécuter des tâches de manière plus efficace. Les techniques de IA utilisées reposent sur la prévision des séries temporelles, qui est l'estimation des valeurs d'une ou plusieurs variables à un moment donné projeté dans le futur, et ce processus est appliqué dans divers domaines tels que l'énergie renouvelable, la médecine, l'économie, l'industrie, etc.

L'économie est marquée par une croissance continue de la production d'énergie renouvelable dans le monde entier, en raison de l'augmentation de la demande en énergie propre et durable. Ce qui a entraîné un intérêt pour l'évaluation et la prédiction de ces sources d'énergie qui ont été intensément étudiées en raison de l'augmentation de la demande et des enjeux environnementaux importants liés à son exploitation. Une prévision précise de ces ressources est essentielle pour prendre les décisions les plus efficaces et optimiser l'exploitation des énergies renouvelables. L'utilisation de l'intelligence artificielle dans la prédiction de la production d'énergie renouvelable peut aider à optimiser son utilisation et à réduire les coûts. En effet, cette prouesse de technologie apporte des solutions innovantes pour une meilleure gestion.

Il existe de nombreux modèles conçus pour prédire les séries temporelles de données météorologiques, parmi lesquels sont les plus connus on retrouve la chaîne de Markov[38], et le processus stochastique. On s'intéresse principalement aux Réseaux de Neurones Artificiels (RNA), principal sujet de cette étude, qui sont devenus une des approches les plus prometteuses pour la résolution des problèmes complexes. Avec les avancées de la science de l'information et la disponibilité des données, les RNA sont devenus un défi scientifique et technologique actuel. En effet, Les communautés météorologiques et hydrologiques s'intéressent de plus en plus à cette technique en raison de son succès élevé dans de nombreuses applications de prédiction, notamment dans le domaine des énergies renouvelables. De nombreux travaux de recherche ont montré que les RNA sont capables de prédire avec précision les séries temporelles de données météorologiques. C'est pourquoi, Cette technique présente des avantages tels que la simplicité et la rapidité d'exécution, ce qui améliore les simulations.

La Recherche Opérationnelle (RO) est une branche des mathématiques appliquées qui s'intéresse à la résolution des problèmes complexes et l'optimisation de l'utilisation des ressources dans divers domaines, tels que l'industrie et le secteur public. Cette approche utilise des techniques des séries temporelles et des réseaux neuronaux pour fournir des solutions.

Dans cette étude, une nouvelle approche est proposée pour améliorer la précision des prévisions du rayonnement solaire. Cette nouvelle approche consiste à établir un modèle ANN de prévision de séries temporelles de rayonnement solaire.

Il convient de noter que les données utilisées pour l'entraînement du modèle MLP sont basées sur des données de réanalyse de haute précision à long terme « Big Data » tirées de la plateforme de la NASA (National Aeronautics and Space Administration) ; "The Modern-Era Retrospective analysis for Research and Applications, Version 2", (MERRA-2), [19], validé par A.Khatibi et S.Krauter ce qui rend ce modèle MLP très fiable et précis.

Le modèle développé a été évalué à (35.63° N 0.60° W), dans le nord-ouest de l'Afrique, qui est une zone côtière caractérisée par un climat méditerranéen semi-aride. La précision du modèle ANN a été évaluée par rapport à une année de réanalyse quotidienne du rayonnement solaire, et les statistiques d'erreur ont été présentées. Il convient de noter que la précision du modèle ANN développé peut également dépendre de la quantité et de la qualité des données utilisées pour former les modèles ; elle peut également dépendre de la variabilité du climat dans la zone d'étude. De plus, ce modèle peut être utilisé pour estimer les données quotidiennes

manquantes en raison du mauvais fonctionnement des dispositifs de mesure déjà installés. Une validation indépendante dans chaque zone d'intérêt reste nécessaire.

Ce mémoire est organisé en quatre chapitres : le premier chapitre portera sur les définitions et les notions de bases des réseaux de neurones, dans le second chapitre nous présenterons les séries temporelles et leur relation avec le Perceptron MultiCouches (PMC), dans le chapitre suivant, nous présenterons les données utilisées ainsi que les procédures pour la conception d'un réseau neuronal. Enfin, le dernier chapitre est consacré à l'implémentation d'un modèle et l'explication du résultat avec le langage de programmation PYTHON [23], et nous terminerons par une conclusion.

Chapitre 1 : Réseaux de neurones artificiels.

1.1 Introduction et historique

1.1.1 Introduction

L'intelligence artificielle, en progression constante depuis l'invention de l'ordinateur et l'utilisation des programmes informatiques, est capable de réaliser des opérations de plus en plus complexes telles que la reconnaissance de spams et de virus, le diagnostic de cancers etc. L'apprentissage profond (Deep Learning DL) est un sous domaine d'intelligence artificielle, dérivée d'apprentissage automatique (Machine Learning ML), permet de créer des techniques et des algorithmes qui peuvent apprendre et s'améliorer de manière autonome. Parmi ces modèles, on compte les réseaux de neurones artificiels.

Dans ce chapitre, nous allons présenter les réseaux de neurones artificiels d'un point de vue général.

1.1.2 Historique

-**1943** : Le champ des réseaux de neurones a démarré par la présentation de J. McCullough et Walter. Pitts dans leur article scientifique intitulé 'A Logical Calculus Of The Ideas Immanent Of Nervous Activity', ils ont créé le premier modèle du **neurone formel** qui est une abstraction du neurone physiologique.

-**1949** : D. Hebb présente dans son ouvrage "**The Organization of Behavior**" une règle d'apprentissage. De nombreux modèles de réseaux aujourd'hui s'inspirent encore de la règle de Hebb.

-**1958** : F. Rosenblatt développe le modèle du Perceptron, un type de réseau de neurones inspiré du système visuel. C'est le premier système artificiel capable d'apprendre par expérience. Dans la même période, le modèle de L'Adaline a été présenté par B. Widrow, chercheur américain à Stanford. Ce modèle sera par la suite le modèle de base des réseaux multicouches.

-**1969** : M. Minsky et S. Papert publient un précis mathématique du perceptron en démontrant qu'il ne peut pas résoudre tout problème tel que le problème de l'XOR. En 1972, T. Kohonen présente ses travaux sur les mémoires associatives et propose des applications à la reconnaissance de formes.

-**1982** : J. Hopfield, physicien reconnu, présente son étude d'un réseau complètement rebouclé, en publiant un article introduisant un nouveau modèle de réseau de neurones.

-**1984** : c'est la découverte des cartes de Kohonen avec un algorithme non supervisé basé sur l'auto-organisation et suivi une année plus tard par la machine de Boltzman (1985).

Avec la croissance exponentielle des données et l'augmentation de la puissance de calcul, les réseaux de neurones ont connu un essor important dans les années 2000 et au-delà. Les réseaux de neurones artificiels sont devenus une technologie clé pour de nombreuses applications dans divers domaines [1].

1.2 L'intérêt de l'utilisation des réseaux de neurones artificiels

Les réseaux de neurones artificiels tirent leur intérêt de la structure parallèle, de la capacité d'adaptation et de la mémoire distribuée. Ces propriétés sont à l'origine d'une capacité des réseaux de neurones à adopter des comportements corrects (interpolation et extrapolation) face à des situations nouvelles, qui ont permis de répondre à des variables d'entrée qui n'ont pas été rencontrées lors de la phase d'apprentissage [2].

Les réseaux de neurones ont été largement utilisés dans le traitement de données visuelles, textuelles et sonores et la prédiction des séries chronologiques. Ils sont également très flexibles dans divers domaines tels que la finance, la santé, la sécurité, etc [3].

1.3 Notions de base sur les réseaux de neurones artificiels

1.3.1 Différents neurones

Le cerveau humain, est le meilleur modèle de machine, polyvalent, rapide, versatile et

il est également remarquable pour sa capacité à effectuer plusieurs tâches en même temps. C'est grâce à la structure de son système nerveux que ce dernier est composé de milliards de cellules nerveuses reliées entre eux, appelées « neurones », qui transmettent des informations dans tout notre corps. Les neurones peuvent être divisés en deux catégories : les neurones biologiques et les neurones artificiels.

1.3.1.1 : Neurone biologique

Le neurone biologique est l'unité de base du système nerveux central. Il est composé de trois régions principales : le corps cellulaire, les dendrites, l'axone et également les synapses.

-Le corps cellulaire : appelé aussi cellule somatique (Soma), joue le rôle d'un sommateur et fait la somme des informations qui lui parviennent grâce à des branches appelées « dendrite ». Il traite ensuite l'information et renvoie le résultat sous forme de signaux électriques du corps cellulaire à l'entrée des autres neurones au travers de son axone.

-Les axones : les axones qui connectent les neurones entre eux permettent également de diffuser le signal du neurone vers d'autres cellules, ils jouent donc un rôle important dans le comportement logique de l'ensemble.

-Les dendrites : on les trouve sous forme de filaments courts et ramifiés, ils sont les récepteurs principaux du neurone, par lesquelles l'information venue de l'extérieur est transportée vers le corps cellulaire.

-Les synapses : elles reçoivent les informations des autres neurones via l'axone et permettent aux neurones de communiquer entre eux, elle joue donc un rôle dans la modulation des signaux qui transitent le système nerveux [28] [29] [30].

La figure suivante représente un neurone biologique :




Figure 1 - Neurone Biologique

1.3.1.2 Neurone formel (artificiel)

Le neurone formel est la composante principale d'un réseau de neurones artificiels, son fonctionnement est inspiré de la conception des neurones biologique

Ce neurone formel peut être considéré comme un opérateur mathématique recevant un nombre de variable d'entrées en provenance de l'extérieur ou d'autres neurones, chacune de ces entrées est pondérée par un poids dit poids synaptique, et fournissant une sortie seulement quand la somme dépasse un certain seuil interne.

Ceci peut être modélisé par la formule suivante [38] :

$$n_i = \sum_{j=1}^N x_j w_{i,j} - b \quad (1,1)$$

$$Y=f(n_i)$$

Tel que :

n_i : potentiel du neurone

x_j : sont les signaux d'entrée (peuvent être booléennes, binaires (0,1), bipolaire (-1,1) ou réels)

$w_{i,j}$: Désigne le poids de la connexion reliant l'entrée j au neurone i.

Y : La sortie du neurone.

b : biais.

f : La fonction d'activation.

La figure suivante représente un neurone artificiel :




Figure 2 - Neurone Artificiel

Les éléments de ressemblance, qui nous permettront de voir clairement la transition entre le neurone biologique et le neurone formel sont récapitulés dans le tableau ci-dessous :

Neurones biologiques	Neurones artificiels
Synapses	Connections pondérées
Axons	Sorties
Dendrite	Entrées
Sommateur	Fonction d'activation

Tableau 1 - Analogie entre le neurone biologique et le neurone formel

1.3.1.2.1 Perceptron simple

Le perceptron simple ou le perceptron à une seule couche est le premier modèle de neurones proposé en 1958 par Franck Rosenblatt [31], C'est le réseau le plus simple puisqu'il ne se compose que d'une couche d'entrée et d'une couche de sortie.

Lors de son développement initial, ce réseau simple a suscité beaucoup d'intérêt en raison de sa capacité à apprendre à identifier des modèles simples, il peut aussi être utilisé dans diverses applications de classification binaire.

1.3.1.2.2 Le Perceptron Multicouche (PMC)

Contrairement au perceptron simple le perceptron multicouche résout les limites du perceptron simple en traitant des données non linéairement séparables grâce à sa structure de réseau de neurones plus complexe.

Le perceptron multicouche se caractérise par une couche d'entrée, un certain nombre de couches intermédiaires (dite couches cachées) et une couche de sortie. Les neurones de la première couche reçoivent le vecteur d'entrée, ils calculent leurs sorties qui sont transmises aux neurones de la deuxième couche qui calculent eux même leurs sorties et ainsi de suite de couche en couche jusqu'à celle de sortie. Chaque neurone dans une couche est connecté à tous les neurones de la couche précédente et de la couche suivante (excepté pour les couches d'entrée et de sortie), et il n'y a pas de connexions entre les cellules d'une même couche donc le flot d'information passe de la couche d'entrée vers la couche de sortie.

La figure ci-dessous montre Présentation du réseau de neurones Perceptron multicouches [38]:




Figure 3 - Présentation du réseau de neurones Perceptron multicouches

1.3.2 Fonctions d'activation

Dans les réseaux de neurones artificiels, la fonction d'activation est une fonction mathématique qui permet de transformer les données et est appliquée à la sortie de chaque neurone artificiel. Cette fonction de transfert, qui tire son nom de l'équivalent biologique "potentiel d'activation", correspond au seuil de stimulation biologique qui, une fois atteint, déclenche une réponse du neurone. [4]

Son rôle est très important et consiste à renvoyer une valeur représentative de l'activation du neurone, cette fonction a comme paramètre la somme pondérée des entrées ainsi que le seuil d'activation. La nature de cette fonction diffère selon le réseau.

Voici les principales fonctions d'activations que l'on peut trouver dans le domaine des réseaux de neurones : [5]

-Fonction linéaire : Les unités de sortie seront identiques à leur niveau d'entrée et est définie par la forme suivante :

$$f(x) = x \quad (1,2)$$

-Fonction Sigmoid (logistic) : Fonction la plus populaire depuis des décennies. Mais aujourd'hui, elle devient beaucoup moins efficace par rapport à d'autre pour une utilisation pour les couches cachées. Elle perd de l'information due à une saturation. Elle est souvent utilisée comme fonction d'activation pour les réseaux de neurones, dans lesquels les valeurs de sortie désirées sont soit binaires soit dans un intervalle compris entre 0 et 1, ce qui permet d'interpréter la sortie du neurone comme une probabilité. Elle est la plus utilisée car elle introduit de la non-linéarité, mais c'est aussi une fonction continue, différentiable. Une fonction sigmoïde(logistique) est définie par :

$$f(x) = \frac{1}{1 + e^{-x}} \quad (1,3)$$

-Fonction Tangente hyperbolique : C'est une fonction bornée à valeurs réelles comprises entre -1 et +1. La fonction tangente hyperbolique est en terme général préférable à la fonction Sigmoïde car elle est centrée sur zéro. Les grandes entrées négatives tendent vers -1 et les grandes entrées positives tendent vers 1. Elle est aussi très utilisée en pratique, car elle partage avec la fonction sigmoïde de certaines caractéristiques pratiques : non polynomiale, indéfiniment continument dérivable et calcul rapide de la dérivée par la formule. Elle est représentée par la fonction suivante :

$$f(x) = \tanh(x) = \frac{1 - e^{-2x}}{1 + e^{-2x}} \quad (1,4)$$

-Fonction ReLU (Rectified Linear Unit) : C'est une fonction des plus populaires de nos jours, elle permet un entraînement plus rapide comparé aux fonctions sigmoid et tanH. Elle est très utilisée pour les perceptrons multicouches.

-Fonction Softmax : Est également appelée fonction exponentielle normalisée. Elle est couramment utilisée pour de la multi classification en couche de sortie. Elle est définie comme :

$$f(x)_i = \frac{e^x_i}{\sum_{k=1}^K e^x_K} \quad (1,5)$$

1.3.2.1 Propriétés de la Fonction d'activation :

La fonction d'activation utilisée pour un neurone artificiel a une grande influence sur son comportement. Il est donc important de choisir judicieusement la fonction d'activation pour obtenir un modèle de neurones utile dans la pratique.

Lorsque les neurones sont combinés dans un réseau de neurones formels, il est important par exemple que la fonction d'activation de certains d'entre eux ne soit pas un polynôme sous réserve de limiter la puissance de calcul du réseau obtenu. Un cas caricatural de puissance limitée correspond à l'utilisation d'une fonction d'activation linéaire, comme la fonction identité : dans une telle situation le calcul global réalisé par le réseau est également linéaire et il est donc parfaitement inutile d'utiliser plusieurs neurones, un seul donnant des résultats strictement équivalents.

1.3.3 Les réseaux de neurones

1.3.3.1 Définition

Un réseau de neurones artificiels, ou Deep Neural Networks en anglais, est un modèle mathématique inspiré de la structure du cerveau humain, c'est un réseau fortement connecté de processeurs élémentaires fonctionnant en parallèle afin de traiter de grandes quantités d'informations en même temps. Chaque processeur élémentaire calcule une sortie unique sur la base des informations qu'il reçoit [6]. Toute structure hiérarchique de réseaux est

évidemment un réseau qui permet d'effectuer des tâches complexes telles que la reconnaissance vocale, la détection d'anomalie ou encore la prévision. [7]

1.3.3.2 Typologie des réseaux de neurones artificiels

L'architecture d'un réseau de neurones dépend de la quantité de neurones qu'il contient et de la manière dont ils sont interconnectés, ces connexions sont caractérisées par des poids et inspirées des neurones biologiques. Les réseaux de neurones sont souvent une solution efficace lorsqu'on dispose de nombreuses données et que l'on ne connaît pas les règles qui régissent les phénomènes que l'on veut modéliser. Le nombre de poids du réseau correspond au nombre total de connexions entre les neurones. Il existe deux structures de réseau distinctes, déterminées par la représentation graphique dans laquelle les neurones sont les nœuds et les connexions sont les arêtes [8] : les réseaux de neurones statiques (aussi appelés acycliques ou non bouclés) et les réseaux de neurones dynamiques (aussi appelés récurrents ou bouclés).

1.3.3.2.1 Réseau de neurones non bouclé

Un réseau de neurones non bouclé ou réseau de neurone à propagation directe (feed-forward en anglais) est constitué d'un ensemble de neurones interconnectés sans retour en arrière de l'information, ce qui signifie que l'information circule uniquement des entrées vers les sorties. Si on représente le réseau sous forme de graphe, où les nœuds sont les neurones et les arêtes sont les connexions entre eux, le graphe d'un réseau non-bouclé est acyclique.

Les réseaux de neurones non bouclés sont des objets statiques qui ne change pas avec le temps cela signifie que si les entrées sont indépendantes du temps, les sorties le sont également. Ils sont utilisés notamment pour les tâches d'approximation de fonction non linéaire, de classification ou de modélisation de processus statiques non linéaires.

La figure suivante montre un réseau de neurones non bouclés [38]:




Figure 4 - Un réseau de neurones non bouclés (Perceptron multicouche)

1.3.3.2 Réseau de neurones bouclé

Les réseaux de neurones récurrents est un type de réseau de neurone formel identifié par des boucles de rétroactions où est transmise l'information vers une couche précédente, ils ont des connexions récurrentes qui leur permettent de prendre en compte les sorties précédentes comme entrées supplémentaires et ainsi de développer une mémoire. Ils sont souvent utilisés pour traiter des données séquentielles, telles que la reconnaissance vocale, la traduction et la reconnaissance de l'écriture manuscrite, ou des séries temporelles et sont capables de prendre en compte l'historique des données précédentes pour prédire les données futures.

La figure suivante montre un réseau de neurones bouclés :




Figure 5 - Forme canonique d'un réseau de neurones bouclés

1.4 Apprentissage des réseaux de neurones

La propriété la plus intéressante des réseaux de neurones est sans doute leur capacité d'apprentissage, qui correspond à la phase de développement des réseaux de neurones où le comportement du réseau est ajusté jusqu'à ce qu'il atteigne le comportement souhaité.

1.4.1 Le type d'apprentissage des réseaux de neurones artificiels

On peut classer les types d'apprentissage en deux grandes catégories, l'apprentissage supervisé ou non supervisé.

1.4.1.1 Apprentissage supervisé

L'apprentissage supervisé (en anglais : Supervised Learning) est le modèle d'apprentissage le plus populaire en Machine Learning. Comme son nom l'indique, cela consiste à superviser l'apprentissage de la machine en lui montrant des exemples (des données) de la tâche qu'elle doit réaliser.

Avec l'apprentissage supervisé, la machine peut apprendre à faire une certaine tâche en étudiant des exemples de cette tâche.

Dans le cadre de prévision, l'apprentissage supervisé est considéré comme la méthode de référence, Ce genre d'apprentissage est réalisé à l'aide d'une base d'apprentissage, constituée de plusieurs exemples de type entrées-sorties, en d'autres termes la machine peut apprendre à faire une certaine tâche en étudiant des millions d'exemples de cette tâche [32][33].

La figure suivante représente l'apprentissage supervise [38]:




Figure 6 - l'apprentissage supervise

1.4.1.2 Apprentissage non-supervisé

Contrairement à l'apprentissage supervisé ci-dessus, l'apprentissage non supervisé tire son nom du fait qu'il n'est pas basé sur des données étiquetées ou un enseignant pour guider le processus d'apprentissage. Les algorithmes sont laissés à leurs propres mécanismes pour découvrir et présenter la structure intéressante des données sans qu'il n'y ait de réponse correcte prédéfinie. En d'autres termes, les méthodes d'apprentissage non supervisé sont utilisées pour explorer des modèles et des relations dans les données qui ne sont pas forcément évidents à première vue [34].

La figure suivante montre l'apprentissage non supervisé :




Figure 7 - l'apprentissage non supervise

1.4.1.3 Apprentissage hybride

Cette méthode étant mathématiquement est plus avancée que les deux premières. L'apprentissage hybride est une approche d'apprentissage automatique qui combine deux autres types d'apprentissage. Il s'agit d'une technique qui vise à exploiter les avantages de chaque type d'apprentissage tout en minimisant leurs inconvénients. Plus précisément une partie des poids va être déterminée par apprentissage supervisé et l'autre partie par apprentissage non supervisé.

En général, l'apprentissage hybride est utilisé dans des situations où un seul type d'apprentissage n'est pas suffisant pour résoudre un problème de manière satisfaisante.

1.4.2 Règles d'apprentissage

L'apprentissage d'un réseau de neurones artificiels se base sur des règles d'apprentissage qui décrivent comment les poids des connexions entre les neurones sont ajustés pendant la phase d'apprentissage pour améliorer la capacité de généralisation du réseau et accroître ses performances.

Il existe plusieurs lois d'apprentissage pour les réseaux de neurones, chacune avec ses propres avantages et limites. Parmi les lois d'apprentissage les plus courantes, on peut citer :

La règle de Hebb : c'est la plus ancienne règle d'apprentissage, elle a été introduite par Donald Hebb en 1949. Cette règle stipule que si deux neurones sont activés simultanément (ont mathématiquement le même signe), la force de leur connexion synaptique doit être renforcée, Cette règle est souvent utilisée pour l'apprentissage non supervisé [35].

Loi de Hebb : $\Delta W_{ij} = R a_i a_j$, où :

ΔW_{ij} : poids synaptique

R : constante positive qui représente la force d'apprentissage

La règle de Hopfield : Elle est similaire à la règle de Hebb, à l'exception du fait qu'elle précise l'ampleur du renforcement ou de l'affaiblissement. Sa règle de base est la suivante : si la sortie et l'entrée souhaitées sont toutes deux actives ou toutes deux inactives, il faut augmenter le poids de connexion.

La règle de Widrow-Hoff : Aussi appelée règle delta, cette règle est aussi une version modifiée de la loi de Hebb. Elle consiste à ajuster les poids synaptiques d'un réseau de neurones de manière à minimiser l'erreur de prédiction entre la sortie du réseau et la sortie attendue. Cette règle est particulièrement adaptée pour l'apprentissage supervisé, où les données d'entraînement sont étiquetées avec des sorties attendues.

La règle de rétro-propagation : inventée par Rumelhart, Hinton et Williams en 1986. Cette règle peut aussi être considérée comme une généralisation de la règle Delta pour des fonctions d'activation non linéaire et pour des réseaux multicouches, elle s'utilise pour ajuster les poids de la couche d'entrée à la couche cachée. Les poids du réseau de neurones sont d'abord initialisés avec des valeurs aléatoires avant de procéder à l'apprentissage avec un ensemble de données appelé échantillon d'apprentissage. Chaque échantillon est associé à une valeur cible que le réseau de neurone doit atteindre lorsqu'on lui présente le même échantillon [36].

La règle de correction d'erreurs : Cette règle vise à minimiser l'écart entre la sortie du réseau de neurones et la sortie cible en ajustant les poids du réseau, on peut la résumer dans les étapes suivantes :

1. On commence avec des valeurs des poids de connexions qui sont pris au hasard.
2. On introduit un vecteur d'entrée de l'ensemble des échantillons pour l'apprentissage.
3. Si la sortie ou la réponse n'est pas correcte, on modifie toutes les connexions pour atteindre la bonne réponse.

Il existe aussi plusieurs autres règles d'apprentissage, on peut noter : La Règle d'apprentissage par compétition, Algorithme du gradient conjugué, Algorithme de Fletcher-Reeves, Algorithme de Quasi-Newton, Algorithme de Levenberg-Marquardt, les algorithmes génétiques...etc.

1.5 L'algorithme de rétro-propagation du gradient de l'erreur

L'algorithme de Rétro-Propagation du gradient, également appelé Back-Propagation en anglais, [9] est l'un des concepts fondamentaux de l'apprentissage des réseaux de neurones. Cet algorithme est largement utilisé dans les réseaux de neurones de type feedforward, qui sont des réseaux à propagation directe. Le principe de la rétro-propagation est d'entrer un vecteur d'entrée dans le réseau, de calculer la sortie en propageant les informations à travers les

différentes couches, de la couche d'entrée jusqu'à la couche de sortie en passant par les couches cachées. La sortie obtenue est ensuite comparée à la sortie souhaitée, ce qui permet d'obtenir une erreur. Cette erreur est utilisée pour calculer le gradient de l'erreur, qui est ensuite propagé de la couche de sortie jusqu'à la couche d'entrée, d'où le terme de rétro-propagation. Cela permet de modifier les poids du réseau et d'effectuer l'apprentissage. Ce processus est répété pour chaque vecteur d'entrée jusqu'à ce que le critère d'arrêt soit atteint. L'algorithme de rétro-propagation comprend deux grandes phases :

- 1) Propagation ou ForwardPass : c'est la première phase où pendant chaque itération (Epoch), un ensemble de données d'entrée est donné au réseau, qui les propage à travers les différentes couches jusqu'à atteindre la couche de sortie, produisant ainsi une sortie (output). Si cette sortie ne correspond pas à la cible souhaitée, l'algorithme effectue une marche arrière (de la couche de sortie à la couche d'entrée) pour corriger cette erreur en ajustant progressivement les poids de chaque neurone dans chaque couche.
- 2) Correction de l'erreur BackwardPass : au cours du premier Epoch, le réseau ne fournit généralement pas le résultat attendu, car il doit d'abord apprendre. Pour corriger cela, on calcule l'erreur entre la valeur de sortie produite par le réseau et la valeur cible souhaitée. En général, on utilise la somme quadratique moyenne des erreurs de tous les neurones de sortie, que l'on rétro-propage ensuite dans le réseau.

Les poids du réseau seront changés à chaque itération. Ce changement se fait de sorte à minimiser l'erreur entre la sortie désirée, le target cible et le résultat du réseau à une entrée $\underline{x}_i$, cela se fait par la méthode de descente de gradient. L'algorithme propage en effet le signal d'entrée dans le réseau à chaque itération dans le sens de la sortie afin d'obtenir une sortie et l'on calcule l'erreur entre cette sortie et la sortie désirée. Ensuite, par rétro-propagation, on calcule des erreurs intermédiaires qui correspondent aux couches cachées, pour au final ajuster des poids w_{ij} . [14]

L'algorithme de retro-propagation se définit comme suit :

Algorithme 1 : Rétro-Propagation de gradient de l'erreur

Début

Initialiser tous les poids w_{ij} à de petites valeurs aléatoires dans l'intervalle $[-1, +1]$.

Normaliser les données d'entraînement dans l'intervalle $[0, 1]$.

Tant que (Fonction coût (E) > erreur max V Epoch #<Epoch max) **Faire**

 ↓ **Input** Un vecteur d'entrée x et spécifier le vecteur de sortie désirée d

Calculer les sorties observées en propageant les entrées vers l'avant à travers les différentes couches du réseau de neurones en utilisant la fonction via $f(x) = \frac{1}{1+e^{-x}}$.

Ajuster les poids en rétro-propageant l'erreur observée.

Formule : $x_j^m = f \left(\sum_{i=0}^{L-1} W_{ij} x_i^{m-1} - \theta_j^m \right)$, $0 \leq j \leq N$ et $0 \leq m \leq M$.

Fin Tant que

Fin.

Algorithme 1 - Algorithme de retro-propagation

1.6 Avantages et inconvénients :

1.6.1 Avantages

Les avantages sont nombreux et significatifs, on peut en citer :

- Auto-apprentissage, le réseau de neurone apprend de lui-même et améliore ses résultats.
- Filtrage efficace du bruit dans les données, la capacité d'isoler uniquement les informations dont les réseaux de neurones ont besoin à partir d'un énorme flux continu de données, en ignorant tout bruit parasite.
- Tolérance aux pannes, Les solutions basées sur les réseaux de neurones restent opérationnelles même après la défaillance d'une partie des neurones. Cela peut affecter la précision et/ou la vitesse de l'algorithme mais ses réponses seront toujours logiques, rationnelles et correctes.
- Simple à manier, il s'agit de fournir moins de travail personnel que dans l'analyse statistique classique.
- Vitesse de travail, à la fois par rapport aux algorithmes informatiques conventionnels et par rapport au cerveau humain. Les informations sont émises instantanément.

1.6.2 Inconvénients

Les réseaux de neurones présentent également des aspects négatifs :

- Le problème de la boîte noire, le défaut le plus notoire de tous les réseaux de neurones artificiels est peut-être leur nature de "boîte noire" car les décisions ne sont pas expliquées.
- La quantité de données, la formation nécessite généralement beaucoup plus de données que les algorithmes d'apprentissage automatique traditionnels.
- Possibilité pour que le temps d'apprentissage soit long.
- Difficultés d'interprétation des résultats en termes de connaissance [10].

Conclusion

Les réseaux de neurones artificiels sont des outils très puissants grâce à leur architecture. Ils constituent une technique de traitement de données bien comprise et bien maîtrisée.

Dans ce chapitre, nous avons présenté les notions de bases des réseaux de neurones ainsi que leur intérêt et leur capacité à résoudre des problèmes complexes. Dans le chapitre suivant, nous allons aborder la relation entre le perceptron multicouche et la prédiction des séries temporelles.

Chapitre 2 : Le perceptron multicouche et la prédiction des séries temporelles

2.1 Introduction

L'analyse de séries temporelles est devenue un domaine d'intérêt récent pour l'intelligence artificielle, car des prévisions précises deviennent de plus en plus importantes dans tous les domaines de notre vie quotidienne afin de prendre des décisions plus appropriées.

Les réseaux de neurones multi couches peuvent être utilisés pour prédire une grande variété de séries temporelles, telles que les données météorologiques, les données financière, les données de trafic, les données de production, ...etc. Mais l'un des objectifs principaux de l'étude d'une série temporelle est la prédiction qui consiste à prévoir les valeurs futures d'une série de données qui évolue au fil du temps. Dans ce chapitre on va mettre en contexte la problématique de la prédiction des séries temporelles, en suite on va présenter le formalisme mathématique avec une définition du concept de ces séries, et enfin on termine par une présentation détaillée de l'utilisation des PMC pour la prédiction.

2.2 Domaines d'application

Les séries temporelles sont présentes dans plusieurs domaines d'application, ils sont largement utilisés pour étudier l'évolution d'un phénomène dans le temps, ce qui permet de prendre les meilleures décisions et de planifier des actions futures.

On peut citer quelques domaines pratiques qui sollicitent fréquemment l'analyse des séries temporelles :

Météorologie : Les séries chronologiques sont utilisées pour prévenir les phénomènes météorologiques tels que les températures, les précipitations, les tempêtes, les ouragans, les sécheresses, etc. Ils permettent aux météorologues de comprendre les tendances et les variations des conditions météorologiques à court et à long terme, ce qui est essentiel pour aider les gens à prendre des décisions éclairées en matière de planification des activités extérieures et de sécurité.

Santé : Étant donné la sensibilité du monde face aux pandémies, il est crucial d'analyser l'évolution du nombre de personnes atteintes afin de prendre des décisions sanitaires éclairées. Dans le cas de la pandémie de COVID -19 qui a déstabilisé le monde depuis son apparition, les RNA et les prédictions des séries temporelles ont été utilisés pour prédire la propagation du virus et évaluer l'efficacité des mesures de lutte contre la maladie, Ce qui a permis de guider les décisions des responsables politiques et des professionnels de la santé.

Finance et économétrie : Financièrement les séries temporelles sont généralement utilisées pour comprendre et prévoir les tendances du marché, Ils sont également utiles pour l'évaluation des risques financiers. En effet, l'analyse des tendances et des modèles de comportement du marché à travers des modèles de séries temporelles peut aider les analystes financiers à identifier les signes de perturbations futures. Ces données sont utiles pour permettre aux investisseurs et aux décideurs financiers de prendre des décisions éclairées et de mettre en place des stratégies pour réduire les risques financiers. En économétrie, les séries temporelles sont utilisées pour modéliser les relations entre les variables économiques telles que le Produit Intérieur Brut (PIB), l'inflation et le chômage. En analysant ces modèles de séries temporelles, les économistes peuvent prévoir les tendances économiques futures et évaluer l'impact des politiques économiques sur l'économie.

2.3 Formalisme Mathématique

2.3.1 Définition

Une série temporelle, aussi appelée série chronologique, est une suite d'observations ou de données qui représentent l'évolution d'un phénomène à travers le temps. Cette suite de données peut être indexée par le temps, qui peut être mesuré en jours, mois, années ou autres unités.[11] La longueur de la série est définie comme le nombre d'observations dans la série. Elle est représentée dans un chronogramme, où le temps est sur l'axe horizontal (abscisse) et la valeur observée sur l'axe vertical (ordonnée). Les séries temporelles sont utilisées pour étudier et comprendre les tendances passées d'un phénomène à travers le temps, et pour projeter cette tendance dans le futur en utilisant des outils statistiques ou de probabilités.

Voici un exemple dans la figure suivante [38] du Nombre de passagers par mois (en milliers) dans les transports aériens aux Etats-Unis, de 1949 à 1960 :




Figure 8 - Nombre de passagers (en milliers) dans les transports aériens

2.3.2 Classification des séries temporelles

La classification des séries chronologiques peut se faire selon plusieurs critères, nous citons ici les plus utilisées :

-La nature du temps : Certains phénomènes évoluent de manière continue à travers le temps, comme les données de température mesurées ou les résultats d'un test d'effort cardiaque enregistré en continu. D'autres phénomènes évoluent de manière discrète, comme le nombre de ventes mensuelles d'un produit. Nous évoquons donc la notion de série temporelle à temps discret et continu.

-La nature de l'observation : Certains phénomènes évoluent dans un espace d'états continus comme l'évolution de la température dans un environnement. D'autres phénomènes sont basés sur le comptage comme le nombre de personnes dans une file d'attente. On définit ainsi la notion de série temporelle à valeurs continues ou entières.

-La dimension de l'espace d'états : Il est fréquent de rencontrer des séries temporelles présentant des évolutions simultanées, comme l'évolution du prix de l'or et du taux de change du dollar américain. Ces deux phénomènes peuvent être combinés pour une analyse multivariée. En effet, les séries temporelles sont classées selon la dimension : univariées ou multivariées. [12]

-La linéarité : Les processus aléatoires sont décrits mathématiquement pour décrire leur dynamique, et ces expressions peuvent être linéaires ou non linéaires. Les séries temporelles linéaires présentent une dynamique assez stable et stationnaire, comme l'évolution

des températures saisonnières. Cependant, il existe des séries temporelles, telles que les cours des actions, qui ne peuvent pas être modélisées par des processus aléatoires linéaires en raison de caractéristiques non linéaires telles que les événements imprévus sur le marché. Les séries temporelles sont donc classées suivant leurs linéarités.

2.3.3 Éléments de l'analyse d'une série temporelle

Une série temporelle peut être analysée de différentes manières et lorsqu'on l'étudie il est souvent intéressant de connaître son historique, notamment pour des raisons économiques. La première étape consiste alors à décrire la série en utilisant différentes représentations graphiques telles que le diagramme séquentiel (time plot), l'histogramme pour avoir une idée de la distribution des valeurs et l'histogramme des valeurs absolues pour détecter une éventuelle hétéroscédasticité et repérer les valeurs atypiques. On peut également utiliser des statistiques descriptives courantes telles que la moyenne, la variance, le coefficient d'aplatissement et d'asymétrie. En fonction de l'objectif visé, une même série temporelle peut être analysée de différentes manières.

2.3.4 Les composantes constitutives d'une série temporelle

Une série temporelle Y_t est communément décomposée en [13] :

- une tendance T_t correspondant à une évolution à long terme de la série, elle peut être ascendante, descendante ou stable.

- une saisonnalité S_t correspondant à un phénomène périodique de période identifiée.

Par exemple : en météorologie, température plus faible en hiver qu'en été.

- une erreur ε_t qui est la partie aléatoire de la série (idéalement stationnaire).

On ajoute parfois une autre composante, le cycle C_t qui correspond à un phénomène répétitif régulier (donc prévisible) de période inconnue ou changeante.

Cette décomposition peut être additive $Y_t = T_t + S_t + \varepsilon_t$ ou multiplicative $Y_t = T_t * S_t * \varepsilon_t$.

2.4 PMC séries temporelles

Aujourd'hui, l'utilisation des réseaux de neurones pour résoudre des problèmes de séries temporelles est devenue très privilégiée. Les réseaux de neurones peuvent être utilisés pour prédire la valeur future de la série en utilisant les valeurs passées, cependant, la relation entre ces deux valeurs est souvent non linéaire, ce qui rend la prédiction difficile. Les Perceptrons Multicouches (PMC) sont des modèles universels d'approximation qui sont particulièrement adaptés pour traiter les données séquentielles, Ils peuvent identifier un processus, le mémoriser puis le restituer fidèlement. En raison de leurs caractéristiques fondamentales des signaux, ils peuvent également être utilisés pour l'estimation, la modélisation et la prédiction de séries temporelles.

Des études récentes ont démontré que les réseaux de neurones en forme de PMC, s'ils étaient correctement spécifiés, peuvent considérablement réduire les erreurs de prévision des séries temporelles. Dans cette section, nous allons présenter une vue d'ensemble de cette méthodologie dans le contexte des séries temporelles. Pour établir la prévision, un nombre fixe de "p" valeurs passées sont définies comme entrées du PMC et la sortie représente la prédiction de la valeur future des séries temporelles.

Lorsqu'on crée des modèles de séries temporelles, il est impossible d'obtenir toutes les informations nécessaires pour établir des prévisions précises. Néanmoins, en utilisant l'historique disponible et en combinant ces données, nous pouvons réduire significativement la marge d'erreur de nos prévisions.

La figure ci-dessous [38] représente l'architecture de base d'une application PMC pour la prévision de séries temporelles pendant la tâche d'apprentissage :




Figure 9 - Présentation de l'application du PMC à la prédiction des séries chronologiques

Conclusion

En somme, les PMC sont un outil très puissant pour la prédiction des séries temporelles grâce à leur capacité à identifier des relations complexes et à prendre en compte l'historique des données. Ils sont utilisés dans divers applications industrielles et scientifiques pour fournir des prévisions précises et fiables.

Chapitre 3 : Conception et élaboration des modèles de prévision d'énergies renouvelables.

3.1 Introduction

Les techniques d'intelligence artificielle basées sur les réseaux de neurones sont de plus en plus utilisées dans plusieurs domaines, dont l'un des plus importants est la prévision de séries chronologiques de données météorologiques. Ce domaine représente actuellement un défi majeur sur le plan scientifique et technologique, mais en utilisant des algorithmes entraînés à partir des données météorologiques passées et présentes, il est possible d'estimer les conditions atmosphériques futures avec une certaine précision. Ces techniques sont particulièrement importantes pour les prévisions climatiques liées aux ressources énergétiques renouvelables.

Dans ce chapitre, nous allons détailler les différentes sources de données météorologiques utilisées pour réaliser cette étude. Nous commencerons par une présentation générale des données, suivies d'une description plus détaillée. Nous nous concentrerons particulièrement sur MERRA-2, un ensemble de données de réanalyse atmosphérique de la NASA, qui sont largement utilisées pour développer ces modèles de prévision en raison de leurs avantages spatio-temporels.

3.2 Contexte de réalisation

3.2.1 Environnement matériel

Pour la réalisation de ce travail, il est nécessaire de disposer d'un environnement matériel adéquat. Les principales caractéristiques des machines utilisées pour implémenter et tester notre application sont présentées dans le tableau suivant :

	RAM	CPU	Marque	Système d'exploitation
PC1	8Go	IntelCorei3- 1005G1	HP	Windows10 64Bit
PC2	6Go	IntelCorei5-2450M	HP	Windows10 64Bit

Tableau 2 - La configuration matériel pour la réalisation de projet

3.2.2 Environnement logiciel

La réussite de la réalisation et l'implémentation de ces modèles de prévision dépend en grande partie de l'environnement de travail choisi. Dans cette section, nous exposons les différents outils sélectionnés pour l'implémentation de l'application.

3.2.2.1 Langage utilisé

 **Python** : Python [23] est un langage de programmation de haut niveau, interprété et orienté objet, qui est largement utilisé dans le monde de la programmation. Il est apprécié pour sa simplicité, sa lisibilité et sa syntaxe claire et concise notamment avec l'indentation. Il est utilisé dans plusieurs domaines comme le développement web, machine learning, Data science. Il a une très grande communauté et beaucoup de librairies Open Source.

3.2.2.2 Bibliothèques utilisé

 **Scikit-Learn** : [24] Bibliothèque open source pour python très utilisé dans la machine learning et dans le data science qui facilite la création et l'entraînement de réseaux de neurones. Elle propose des outils mathématiques et statistiques pour l'analyse de données, ainsi que plusieurs algorithmes.

 **Numpy** : [25] Bibliothèque open-source de calcul numérique pour Python. Elle fournit des structures de données de haute performance pour la manipulation de tableaux multi-dimensionnels et des fonctions mathématiques avancées pour l'analyse de données.

 **Pandas** : [26] Librairie open source pour la manipulation de données en python. Elle fournit des structures de données pour traiter des tableaux multidimensionnels, ainsi que des outils pour lire et écrire des données dans différents formats de fichiers.

 **Matplotlib** : [27] Librairie open source pour visualiser les données en python. Elle est conçue pour produire des graphiques de qualité professionnelle

3.3 Présentation et description des données

3.3.1 Présentation des données

La base de données fournie pour ce travail est constituée de données météorologiques qui ont une influence sur la production et le développement des énergies renouvelables. Cette base de données est construite à partir de données de haute précision de la NASA, appelées "The Modern-Era Retrospective Analysis for Research and Applications, Version 2" [19] (MERRA 2).

3.3.2 Description des données :

3.3.2.1 MERRA-2

MERRA-2 est une collection de données climatiques globales qui comprennent une large gamme de variables atmosphériques, notamment la température, la pression, l'humidité, les précipitations, le vent et le rayonnement solaire...etc. Cette dernière a été produite par Le Global Modeling and Assimilation Office (GMAO) de la NASA. Ces données sont présentées sur une grille horizontale uniforme de 576 points dans la direction longitudinale et 361 points dans la direction latitudinale avec une résolution spatiale de $0,625^\circ \times 0,5^\circ$. La résolution longitudinale des données est modifiée par rapport à MERRA (passant de $0,667^\circ$ à $0,625^\circ$), tandis que la résolution latitudinale reste inchangée ($0,5^\circ$) [20]. Donc MERRA-2 a été développé pour remplacer l'ancienne réanalyse MERRA et pour résoudre ses limites dans l'assimilation des sources les plus récentes des données de satellite [21]. MERRA-2 couvre une période suffisamment longue allant de 1980 à aujourd'hui, ces données ont été évaluées et validées par les chercheurs KHATIBI et KRAUTER [22] par rapport aux données des stations de mesure des institutions météorologiques telles que Meteonorm et Deutscher Wetterdienst. Les données MERRA-2 présentent l'avantage de pouvoir être utilisées pour étudier des phénomènes météorologiques ou climatiques à grande échelle, ou pour des régions où les données de mesure sont absentes ou couvrent une courte période comme les régions côtières et marines. Leur exploitation peut être plus bénéfique sur le plan spatial et temporel, mais il est important de noter que les données de mesure expérimentales ont généralement plus précises et fiables. Ainsi, si de telles données expérimentales étaient disponibles, il serait préférable de

les utiliser plutôt que de se fier uniquement aux données de réanalyse comme celles fournies par MERRA-2.

3.4 Les procédures de développements et élaborations des modèles RNA

Cette application web utilise des technologies open source pour créer des modèles de prévision journalière pour n'importe quelle zone géographique. Des scripts sont utilisés pour développer des modèles avec des architectures de réseaux optimisées pour un équilibre entre simplicité et précision.

Nous avons pour méthode de combiner les techniques d'optimisation multi-objectifs, de séries temporelles et de réseaux de neurones pour utiliser le formalisme de prévision.

Pour développer un modèle de réseau de neurones artificiels, les principaux paramètres qui influencent l'architecture et l'apprentissage sont le nombre de données d'entrée, le nombre de couches cachés, la fonction d'activation, le type d'apprentissage et la fonction de comparaison utilisée lors de la phase d'apprentissage. Le cycle de développement des modèles de réseau de neurones artificiels se déroule en cinq étapes principales : collection et séparation de la base des données, prétraitement des données, l'architecture PMC séries temporelles, apprentissage et paramétrage du modèle, et phase de test.

3.4.1 Collection et séparation de la base de données

L'objectif de cette étape est de collecter suffisamment de données pour créer une base de données représentative qui sera utilisée pour l'apprentissage et le test du réseau de neurones. Cette base de données détermine la taille du réseau et ses performances en termes de capacité de généralisation [38].

Après avoir créé une base de données, nous avons utilisé des fonctions prédéfinies de python pour séparer les données en trois ensembles : un ensemble d'apprentissage pour entraîner le modèle, un ensemble de validation pour vérifier la capacité de généralisation du réseau et arrêter l'apprentissage, et un ensemble de tests pour tester les performances du réseau.

Les ensembles d'entraînement et de validation contiennent la plupart des données car ils sont utilisés pour ajuster les poids de connexion des neurones lors de l'entraînement. Le but

de l'entraînement est de trouver les poids optimaux pour les différentes connexions afin que le réseau puisse acquérir des connaissances.

3.4.2 Prétraitements des données

Avant l'apprentissage, il est important de prétraiter les données pour les adapter aux entrées et sorties du réseau de neurones et pour s'assurer que les valeurs propagées dans le réseau soient homogènes. Ce prétraitement est la normalisation des variables d'entrée et est généralement nécessaire car les valeurs des vecteurs d'entrée et de sortie des réseaux de neurones peuvent être très différentes. Si ces valeurs sont trop décalées, le réseau risque d'être saturé ou de ne pas réussir à apprendre.

Il existe plusieurs techniques de normalisation de données, telles que la mise à l'échelle Min-Max, la normalisation Z-score, la normalisation par décile, la normalisation médiane, la normalisation Sigmoidale, et l'estimateur de Tanh. Chacune de ces techniques a des avantages et des inconvénients, Il n'y a pas de technique de normalisation de données qui soit la meilleure pour tous les types de données et tous les type de modèles de Machine Learning, donc le choix dépend du ces deux derniers.

Cependant, D'après D. Cebrián,[15] la méthode de la normalisation Min-Max est souvent préférée lorsqu'il est important de conserver les valeurs minimales et maximales d'origine, cette méthode est la plus efficace pour améliorer l'état des données d'entrée, accélérer l'apprentissage et avoir un impact positif sur le temps. Il est donc fortement recommandé de normaliser les données c'est à dire de rendre les valeurs plus proches les unes des autres. Les entrées et sorties sont normalisées linéairement entre 0 et 1(i.e. [0,1]), par rapport à leur valeur minimale ou maximale, en appliquant l'équation de normalisation suivante :

$$N(E) = \frac{E - Min}{Max - Min} \quad (3,1)$$

Où $N(E)$ est la valeur normalisée, E est la valeur brute, Min et Max sont respectivement la valeur minimale et la valeur maximale enregistrée sur cette base de données. Cette normalisation correspond à l'opération réalisée juste avant l'apprentissage des PMC.

3.4.3 L'architecture PMC séries temporelles

Le choix du nombre de couches et de neurones dans chaque couche est crucial pour la performance et l'apprentissage du réseau de neurones artificiels. En effet, une bonne architecture peut optimiser la durée de l'apprentissage et donner les meilleurs résultats avec une faible estimation d'erreur. Cependant, il n'existe pas de règles systématiques ou de méthode mathématique pour déterminer le nombre optimal de couches et de neurones, et cela peut nécessiter une expérience pratique et des compétences. Il est important de noter que le nombre de couches et de neurones détermine la capacité de calcul du réseau et la méthode la plus efficace consiste à tester un grand nombre d'architectures différentes pour trouver la meilleure option. De plus, Il est recommandé que la taille du PMC soit aussi simple que possible, selon le principe de parcimonie, quel que soit le nombre d'entrées. Pour illustrer cela, nous avons entraîné le réseau à partir des données d'une série temporelle, afin de prédire la valeur de la date suivant la date finale. On adopte la méthode qui consiste à prendre les séquences de p jours $(x_t, x_{t-1}, \dots, x_{t-p})$ pour prédire chaque (x_{t+1}) -ème jour. Dans l'ensemble d'entraînement, le x_{t+1} ème jour est la valeur supervisée, un nombre fixe p de valeurs des séries temporelles passées sont définies comme des entrées du PMC, et les sorties sont les futures valeurs de données de série temporelle x_{t+1} . [16] La méthode utilisée est « La technique de la fenêtre glissante » qui consiste à utiliser une fenêtre temporelle mobile pour sélectionner un ensemble de p entrées de données sur une période de n temps, afin de les utiliser pour l'entraînement du réseau.

3.4.4 Apprentissage et paramétrage du modèle

Les réseaux de neurones, comme la plupart des méthodes d'apprentissage, sont formalisés comme des problèmes d'optimisation visant à minimiser des erreurs sur les données observées en ajustant les paramètres du modèle de prédiction.

En utilisant un algorithme d'apprentissage, les réseaux de neurones modifient les poids synaptiques en fonction des données d'entrée présentées. Bien que le choix du poids initial soit important pour la convergence de l'algorithme, la manière dont les données sont présentées au réseau est également essentielle pour sa performance. L'algorithme d'apprentissage rétropropagation de l'erreur est la pièce maitresse pour entraîner les neurones des couches cachées dans les réseaux multicouches de type PMC.

L'algorithme de rétropropagation du gradient est un algorithme itératif qui permet de minimiser l'erreur du réseau sur l'ensemble d'apprentissage en ajustant les poids des connexions, il est utilisé pour résoudre des problèmes complexes dans de nombreux domaines. Pour obtenir une performance optimale, il est nécessaire de régler différents paramètres tels que la fonction de transfert, l'architecture du réseau, le nombre de couches, le nombre de neurones par couche et l'initialisation des poids.[17]

L'utilisation d'une fonction de transfert de type sigmoïde qui produit des sorties dans l'intervalle $[0,1]$ peut fournir une bonne approximation de différents types de fonctions, y compris l'estimation de données météorologiques.

Dans notre application web, nous utilisons l'algorithme d'apprentissage de rétropropagation et la fonction de transfert sigmoïde pour estimer les paramètres des réseaux de neurones artificiels avec une analyse multi-objectifs pour les PMC afin d'obtenir les meilleures performances. La formation du réseau neuronal est essentielle pour qu'il puisse apprendre à partir d'exemples historiques et produire des réponses de sortie précises pour les données de formation. Ensuite, des tests sont effectués pour évaluer la qualité de généralisation du réseau neuronal en utilisant une base de données différente de celles utilisées pour la formation et la validation. Ces tests permettent de vérifier la capacité du réseau à prédire avec précision les nouvelles données et à minimiser l'erreur.

3.4.5 Phase de test

Après avoir terminé l'apprentissage du réseau neuronal, il est essentiel de tester ses capacités de généralisation en lui présentant une base de données différente de celles utilisées pour l'apprentissage et la validation. Si les performances ne sont pas satisfaisantes, des ajustements peuvent être effectués en modifiant soit l'architecture du réseau, soit la base d'apprentissage.

Chapitre 4 : La prévision journalière de la série chronologique de rayonnement solaire.

4.1 Problématique et objectif

L'énergie solaire est une source d'énergie renouvelable qui dépend du rayonnement solaire, l'une des principales sources d'énergie renouvelable souvent utilisé dans la production d'électricité, de chaleur et de froid. [18] Elle peut être captée et transformée en électricité à l'aide de panneaux solaires, aussi appelé panneaux photovoltaïques. L'énergie solaire est considérée comme une solution alternative aux combustibles fossiles car elle est abondante, propre gratuite, disponible dans de nombreuses régions et ne génère pas de gaz à effet de serre. Le rayonnement solaire est considéré comme l'un des paramètres météorologiques clés pour la prévision des performances des systèmes d'énergie renouvelable et est particulièrement important pour le dimensionnement des systèmes d'énergie photovoltaïque, les applications agricoles et dans la conception de bâtiments.

Les informations relatives au rayonnement solaire jouent un rôle crucial dans la conception, l'évaluation et l'optimisation des performances des technologies d'énergie solaire ainsi que pour les applications pratiques sur le terrain. Leurs mesures sont rares et non disponibles ou même insuffisantes sur la plupart des sites géographiques. Par ailleurs, Mubiru et Banda ont démontré que les réseaux de neurones artificiels (RNA) sont plus précis que les méthodes empiriques pour estimer le rayonnement solaire, car ils sont capables de traiter la nature non linéaire et non stationnaire de cette donnée. Ainsi, la prédiction du rayonnement solaire par les RNA est recommandée pour une gestion optimale des ressources en énergie solaire. La précision de la prédiction ou de la mesure des séries temporelles de données sur le rayonnement solaire est considérée comme la première étape de l'évaluation de la disponibilité de l'énergie solaire.

Il est remarquable de noter que l'Algérie est probablement le pays africain et méditerranéen disposant du potentiel d'énergie solaire le plus important à l'échelle régionale (voire même mondiale) en ce qui concerne la prévision de l'énergie solaire.

Les résultats de la présente étude mettent en évidence la supériorité des techniques de réseaux de neurones artificiels pour la prédiction du rayonnement solaire par rapport aux

méthodes conventionnelles. Nous avons observé une amélioration significative de la précision des prévisions en utilisant les modèles de réseaux de neurones, ce qui démontre leur efficacité dans la prédiction du rayonnement solaire

4.2 Implémentation du modèle RNA

Dans cette partie nous allons exposer le travail achevé. Nous allons présenter l'implémentation de ce modèle RNA de prévision journalière des rayonnements solaires dans le cadre de cette étude.

Les détails de la procédure de mise en œuvre de ce modèle et les résultats obtenus pour la région d'Oran située à la latitude 35.63° N et la longitude 0.60° W, seront présentés dans la suite de ce chapitre.

4.2.1 Présentation des données

Dans le cadre du développement de ce modèle RNA, nous avons utilisé la série temporelle quotidienne du paramètre climatique SWGDN fournie par MERRA-2.

Le SWGDN est un paramètre précieux pour le développement de l'énergie renouvelable solaire dont l'unité est exprimée en mégajoules par mètre carré (MJ/m²). Cela représente l'énergie totale du rayonnement solaire incident par unité de surface (en mètres carrés) au niveau de la surface terrestre. La figure suivante montre une partie des données :

	Id	Station	Lon	Lat	Type Data	Année	M	J	DATA
10913	10959	ES SENIA	-0.625	35.75	SWGDN	2010	1	1	2216.1533
10914	10960	ES SENIA	-0.625	35.75	SWGDN	2010	1	2	2996.5898
10915	10961	ES SENIA	-0.625	35.75	SWGDN	2010	1	3	2936.2422
10916	10962	ES SENIA	-0.625	35.75	SWGDN	2010	1	4	3110.9805
10917	10963	ES SENIA	-0.625	35.75	SWGDN	2010	1	5	1451.6445
10918	10964	ES SENIA	-0.625	35.75	SWGDN	2010	1	6	2402.4180
10919	10965	ES SENIA	-0.625	35.75	SWGDN	2010	1	7	1320.8906
10920	10966	ES SENIA	-0.625	35.75	SWGDN	2010	1	8	2852.0703

Figure 10 - Une partie des données

4.2.2 Collection et séparation de la base de données

L'objectif de cette étape est de construire une base de données destinée à l'apprentissage, la validation et au test du réseau de neurones. Pour notre application, nous avons utilisé la série temporelle des données de réanalyse de rayonnement solaire quotidien (SWGDN) de MERRA-2. Cette série couvre une période de 10 ans allant du mois de janvier 2010 au mois de décembre 2019, ce qui nous permet de créer une base de données composée de 3652 jours.

Après avoir établi la base de données, il est nécessaire de procéder à la phase de séparation en trois ensembles. Dans le présent travail, 80 % de l'ensemble de données représente l'ensemble d'apprentissage, 10% pour la validation et l'autre 10 % en tant qu'ensemble de données de test. La figure suivante le montre ainsi :



Figure 11 - Séparation de la base de données

4.2.3 Prétraitement des données

Après la collecte des données, une procédure importante de prétraitement est effectuée pour former les RNA plus efficacement. Cette procédure consiste à normaliser les données linéairement entre 0 et 1 en appliquant la méthode de normalisation Min-Max qui est détaillée dans le chapitre précédent.

4.2.4 Architecture du modèle RNA

Après l'entraînement du modèle de réseau de neurones artificiels (ANN) de type PMC avec les données mentionnées précédemment d'une date initiale à une date finale, afin de prédire la valeur correspondante à la date suivante. Le réseau de neurones a été conçu avec un nombre prédéterminé d'entrées et de sorties ; le rayonnement solaire sur une période de 6 jours précédant le jour à prédire a été considéré sur la couche d'entrée ($X_t \dots X_{t-5}$) prédire chaque

X_{t+1} jour, dans l'ensemble d'apprentissage, ainsi le 7ème jour correspond à la valeur de sortie supervisée.

4.2.5 Apprentissage et configuration

Notre approche consistait à partir d'une architecture simple avec un nombre minimum de neurones dans la couche cachée, puis à la rendre progressivement plus complexe. Nous avons commencé par entraîner un modèle avec une seule couche cachée contenant un seul neurone, puis nous avons augmenté progressivement le nombre de couches cachées jusqu'à atteindre trois couches, ainsi que le nombre de neurones dans chaque couche jusqu'à 100. Nous avons choisi de limiter le nombre de couches cachées à trois et le nombre de neurones dans chaque couche à 100 afin d'éviter un surapprentissage. Les modèles ont été développés en utilisant l'algorithme de rétropropagation avec une fonction d'activation sigmoïde pour les couches cachées. Cette approche nous a permis de trouver la performance optimale du modèle tout en évitant une complexité excessive.

4.2.6 Évaluation de la précision du modèle RNA

Afin d'évaluer quantitativement la performance des modèles RNA, il est important d'utiliser des mesures d'évaluation appropriées qui permettent de calculer l'erreur entre les valeurs prédites et les valeurs réelle. Cette différence est également appelée perte, moins elle est importante, mieux c'est. Le comportement de la perte aide le modèle à comprendre ce qui doit être fait pour optimiser le modèle afin que la perte puisse être réduite. Dans notre application, deux paramètres d'erreur ont été calculés, l'erreur absolue moyenne (MAE) et l'erreur quadratique moyenne (RMSE) :

— **L'erreur quadratique moyenne (Mean Square Error ; MSE)** : elle est calculée en prenant la somme des carrés des différences entre les valeurs prédites et les valeurs réelles, puis en divisant cette somme par le nombre total de prévision

$$MSE = \frac{1}{N} \sum_{i=1}^N (P_i - O_i)^2 \quad (4,1)$$

Le RMSE (Root Mean Squared Error) est une mesure d'évaluation similaire à la MSE (Mean Squared Error), mais elle a l'avantage d'être plus facilement interprétable car elle est exprimée dans les mêmes unités que la variable cible.

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (P_i - O_i)^2} \quad (4,2)$$

— **L'erreur moyenne absolue (MeanAbsoluteError ; MAE) :** Elle représente la moyenne de la différence absolue entre les valeurs réelles et prédites dans l'ensemble de données. Sa formule est donnée par :

$$MAE = \frac{1}{N} \sum_{i=1}^N |P_i - O_i| \quad (4,3)$$

Où N est le nombre total de prévision, O_i et P_i sont respectivement les données réelles et les données prédites.

4.3 Résultats et discussions

4.3.1 Paramétrage du modèle RNA

Les résultats obtenus suite à l'entraînement de modèle dans une station de référence localisée dans la ville d'Oran sont présentés dans cette section. Le tableau ci-dessous présente les paramètres utilisés pour l'entraînement. L'itération a été fixée à 1000. Le taux d'apprentissage et le facteur d'impulsion ont été fixés à 0,01 et 0,7, respectivement. Le tableau ci-dessous représente les paramètres de performance utilisés pour l'entraînement du modèle :

Les paramètres de performance	Valeur
Nombre d'entrées	6 (valeur du rayonnement solaire des six derniers jours)
Nombre de sorties	1 (valeur du rayonnement solaire du jour suivant)
Nombre de couches cachées	1-3
Neurones par couches.	1-100
Learning rate	0.01
Max itération	1000
Momentum	0.7

Tableau 3 - Paramètres de performance utilisés pour l'entraînement du modèle

4.3.2 Résultats prévisionnels quotidiens et précision

Pour le test et l'évaluation de ce modèle développé, des données collectées entre janvier 2019 et décembre 2019 ont été utilisées. Dans cette période, la série temporelle de rayonnement solaire de 359 jours a été prédite à l'aide de ces modèles.

L'architecture optimale du modèle de prévision du rayonnement solaire quotidien est définie automatiquement pour un nombre maximal de neurones de 100 par couche et un maximum de 3 couches. Après avoir formé le modèle RNA, nous préférons donc identifier les architectures correctes pour les trois couches cachées sur la base de la valeur de l'erreur quadratique moyenne. Ainsi, le choix de l'architecture optimale du modèle RNA est plus robuste car il présente la valeur d'erreur quadratique moyenne la plus faible.

La figure suivante présente les RMSE en fonction du nombre de couches cachées et du nombre de neurones dans chaque couche cachée, parmi lesquelles nous avons sélectionné une architecture qui présente l'erreur quadratique moyenne la plus faible, soit 1032.829 w/m² (ou 3.71 MJ/m²). Cette architecture est constituée de trois couches cachées avec 15 neurones dans chaque couche, et elle est considérée comme l'architecture optimale pour notre modèle de prévision quotidienne du rayonnement solaire.




Figure 12 - Les RMSE en fonction du nombre de couches cachées et du nombre de neurones dans chaque couche cachée (la barre rouge correspond au RMSE le plus faible choisi).

Concernant les statistiques d'erreurs enregistrées pour le modèle RNA dans lesquels les valeurs de RMSE et MAE obtenues pendant la formation et le test sont résumées dans le tableau suivant :

Modèle	Formation		Test	
	RMSE W/(m ² . day)	MAE W/(m ² . day)	RMSE W/(m ² . day)	MAE W/(m ² . day)
RNA	1032.82	741.03	911.14	621.35

Tableau 4 - les performances (statistiques d'erreurs obtenues) pour le modèle ANN pour la formation et la validation.

La figure suivante montre un graphe de séries temporelles des rayonnements solaires (SWGDN) prédites comparées aux rayonnements de MERRA-2 observées durant l'année 2019 pour le modèle MLP. Cette figure montre que le modèles présente une bonne performance dans la prévision journalière des rayonnements solaires mais avec une faible performance dans l'estimation des diminutions brusques qui peuvent être liées à des augmentations brusques dans la nébulosité.




Figure 13 - Courbe chronologique de prédiction de rayonnement solaire SWGDN prédit comparé au SWGDN de MERRA-2 avec RMSE.

En examinant attentivement la courbe de la figure ci-dessus., on constate que la courbe qui représente les prévisions du modèle suit de très près le rayonnement réel, avec seulement une légère marge d'erreur. Cela suggère que notre modèle est capable de fournir des estimations plutôt fiables.

Le diagramme de dispersion (Fig.14) montre également une distribution homogène entre les données prévues et les données de MERRA-2 (SWGDN) pour le modèle ANN, avec une tendance à sous-estimer légèrement les valeurs fortes.




Figure 14 - Diagramme de dispersion

Conclusion

Nous avons présenté dans ce dernier chapitre les résultats détaillés de notre travail : une implémentation d'un modèle RNA pour la prévision quotidienne de la série chronologique du rayonnement solaire a été effectué.

Après avoir confronté les valeurs observées avec celles prédites, et évalué différentes architectures de réseaux de neurones, l'architecture optimale (à savoir trois couches cachées avec 15 neurones) a été choisie pour entraîner et tester le modèle sur une base de données réanalyse de MERRA-2 pour la station d'Oran (35.63° N 0.60° W), sur une période de 10 ans. Les résultats obtenus ont montré que le modèle développé est capable de fournir une meilleure performance dans la prévision journalière des rayonnements solaires. En somme, cette réalisation démontre l'efficacité des réseaux de neurones pour la prévision de la production d'énergie solaire, ce qui peut contribuer à la gestion et à l'exploitation de l'énergie solaire.

CONCLUSION GENERALE

Cette conclusion résume les solutions proposées, les contributions de recherche et les résultats obtenus, ainsi que quelques perspectives pour de futures recherches. Cependant, il convient de souligner que cette étude ne couvre qu'une des nombreuses voies à explorer dans ce domaine et qu'elle nécessite des approfondissements ultérieurs.

L'intelligence artificielle, une révolution technologique en constante évolution, ouvre de nouvelles perspectives pour l'avenir. Elle est sollicitée dans plusieurs domaines de recherche tels que la reconnaissance d'image, la traduction automatique, la reconnaissance vocale, l'analyse de données, la robotique, la prédiction de résultats et la modélisation prédictive, y compris dans l'utilisation des énergies renouvelables.

Le Deep learning est l'une des avancées de l'intelligence artificielle qui utilise des réseaux de neurones artificiels profonds pour apprendre des modèles à partir de données. En effet, les RNA s'inspirent de la structure du cerveau humain pour aider les machines à devenir plus proches des humains.

L'un des principaux défis de l'énergie renouvelable est la difficulté à prédire la production d'énergie à partir de sources. La production d'énergie renouvelable dépend fortement des conditions météorologiques et de la disponibilité de ressources naturelles. Ces facteurs peuvent varier considérablement d'une heure à l'autre, ce qui rend la prévision de la production d'énergie renouvelable très difficile.

C'est là que l'intelligence artificielle entre en jeu. En utilisant des techniques d'apprentissage automatique, il est possible d'analyser de grandes quantités de données météorologiques et de production d'énergie passées pour prédire la production d'énergie renouvelable future avec une précision accrue.

Dans notre travail nous avons proposé la prédiction numérique des séries temporelles grâce aux réseaux de neurones artificiels multicouche comme solution. Ce choix est justifié par sa simplicité et son efficacité.

La création d'une architecture adéquate a toujours été un défi pour la construction de réseaux de neurones, notamment en ce qui concerne le nombre de neurones dans une couche cachée. De plus, contrairement aux prévisions mensuelles, les modèles de prévisions quotidiennes sont souvent insuffisamment documentés.

Une approche a été élaborée pour proposer des solutions aux problèmes mentionnés précédemment. C'est une méthode novatrice qui a été mise en œuvre dans ce mémoire, en utilisant un outil opérationnel pour développer de nouveaux modèles combinant les séries temporelles et les réseaux de neurones.

Notre objectif tout au long de ce travail a été de concevoir une solution plus adaptée à la complexité du phénomène. Nous avons donc concentré nos efforts sur l'élaboration d'une démarche pratique et peu complexe grâce aux réseaux de neurones artificiels.

Dans cette étude nous avons parlé des réseaux de neurones artificiels en donnant leurs types, leurs fonctionnements, le type d'apprentissage et les algorithmes d'apprentissage ainsi que les fonctions d'activation.

Dans le second chapitre, nous avons énoncé quelques définitions relatives aux séries temporelles, leurs domaines d'application mais également leur classification. Comme nous l'avons vu, les données météorologiques peuvent être considérées comme une succession de mesures et donc interprétées comme une série temporelle.

Nous avons vu dans le troisième chapitre la relation entre les réseaux de neurones et les énergies renouvelables et de ce fait, nous avons montré la prévision des séries chronologiques avec un type de réseau neuronal qui est le PMC.

Dans le dernier chapitre, nous avons développé un réseau de neurones pour les prévisions de séries temporelles quotidiennes à travers différents paramètres météorologiques qui contribuent au développement des énergies renouvelables.

Cette étude, comme toute autre, comporte certaines limites qui pourraient faire l'objet d'amélioration lors de futurs travaux, donc comme perspectives, nous pouvons ajouter :

- Tester notre modèle sur l'estimation du rayonnement solaire à partir d'une base de données répartir sur plusieurs régions de l'Algérie.
- Proposer d'autres architectures pour améliorer les résultats.
- On pourrait éventuellement s'intéresser sur la possibilité d'utiliser un algorithme génétique pour avoir une architecture optimale adéquate du réseau de neurones.
- Procéder à de nouvelles recherches liées aux données de réanalyse.

Références bibliographiques

- [1] <https://www.futura-sciences.com/tech/dossiers/robotique-presentation-historique-reseaux-neuronaux-31/>
- [2] <https://virole.pagesperso-orange.fr/RNECPA.PDF>
- [3] <https://praedictia.com/page/reseaux-de-neurones/que-peuvent-faire-les-reseaux-de-neurones.html>
- [4] https://datafranca.org/wiki/Fonction_d%27activation
- [5] <https://deeplylearning.fr/cours-theoriques-deep-learning/fonction-dactivation/>
- [6] <https://csiac.org/wp-content/uploads/2021/06/Artificial-Neural-Networks-Technology-SOAR.pdf>
- [7] <https://www.journaldunet.fr/web-tech/guide-de-l-intelligence-artificielle/1501851-reseau-de-neurones-artificiels/>
- [8] <https://www.ionos.fr/digitalguide/web-marketing/search-engine-marketing/quest-ce-quun-reseau-neuronal-artificiel/>
- [9] <https://python.doctor/page-deep-learning-python>
- [10] <https://merehead.com/fr/blog/avantages-inconvenients-larchitecture-reseau-neuronal/>
- [11] http://biblio.univ-antananarivo.mg/pdfs/andryManantenaKM_PH_MAST_16.pdf
- [12] http://www.jms-insee.fr/2009/S01_0_ACTE_LADIRAY_JMS2009.PDF
- [13] https://www.imo.universite-paris-saclay.fr/~yannig.goude/Materials/time_series/cours2_tendance_composante_saisonniere.pdf
- [14] N.M. Héritier, I.B. Nephtali, L'Algorithme de rétro-propagation de gradient dans le perceptron multicouche : Bases et étude de cas, Int. J. Innov. Appl. Stud. 32 (2021) 271–290. https://www.researchgate.net/profile/Heritier-Nsenge-2/publication/351253657_Corresponding_Author_Nsenge_Mpia_Heritier_L'Algorithme_de_retro_propagation_de_gradient_dans_le_perceptron_multicouche_Bases_et_etude_de_cas_Gradient_Back-Propagation_Algorithm_i.
- [15] D. Cebrián, An Introduction to Artificial Neural Networks, (2021) 11843. <https://doi.org/10.3390/mol2net-07-11843>.
- [16] B.W. White, F. Rosenblatt, Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms, Am. J. Psychol. 76 (1963) 705. <https://doi.org/10.2307/1419730>.
- [17] D. Neurones, R'eseaux de neurones artificiels, 2015. http://frostiebek.free.fr/docs/Reseaux de neurones/RNF_fzzy.pdf.
- [18] <https://www.edf.fr/groupe-edf/espaces-dedies/l-energie-de-a-a-z/tout-sur-l-energie/produire-de-l-electricite/qu-est-ce-que-l-energie-solaire>

- [19] R. Gelaro, W. McCarty, M.J. Suárez, R. Todling, A. Molod, L. Takacs, C.A. Randles, A. Darmenov, M.G. Bosilovich, R. Reichle, K. Wargan, L. Coy, R. Cullather, C. Draper, S. Akella, V.
- [20] <https://gmao.gsfc.nasa.gov/reanalysis/>
- [21] D. Cebrián, An Introduction to Artificial Neural Networks, (2021) 11843. <https://doi.org/10.3390/mol2net-07-11843>.
- [22] A. Khatibi, S. Krauter, Validation and performance of satellite meteorological dataset merra-2 for solar and wind applications, *Energies*. 14 (2021). <https://doi.org/10.3390/en14040882>.
- [23] <https://www.python.org/about/>
- [24] <https://scikit-learn.org/stable/>
- [25] <https://numpy.org>
- [26] <https://pandas.pydata.org>
- [27] <https://matplotlib.org>
- [28] <https://moncoachdata.com/blog/comprendre-les-reseaux-de-neurones/#:~:text=Le%20concept%20de%20r%C3%A9seaux%20de,d%C3%A9clenchent%20un%20signal%20de%20sortie>.
- [29] https://scholar.google.com/scholar?hl=fr&as_sdt=0%2C5&q=les+r%C3%A9seaux+de+neurones&oq=les+r%C3%A9seaux+de+neuron
- [30] <http://www.univ-bejaia.dz/xmlui/discover>
- [31] Rosenblatt, F. (1962). Principles of neurodynamics: Perceptrons and the theory of brain mechanisms. Washington, DC: Spartan Books
- [32] <https://machinelearnia.com/aprentissage-supervise-4-etapes/>
- [33] G. Dreyfus, J.-M. Martinez, M. Samuelides, M.B. Gordon, F. Badran, S. Thiria, Apprentissage statistique : Réseaux de neurones - Cartes topologiques - Machines à vecteurs supports, (2011) 450
- [34] Guillaume Saint –Cirgue, Apprendre Le Machine Learning En Une Semaine ,2019
- [35] M. Parizeau, Le perceptron multicouche et son algorithme de rétropropagation des erreurs, Département Génie Electr. Génie Informatique, Univ. Laval. 1 (2004). <http://wcours.gel.ulaval.ca/2009/h/19968/default/5notes/NotesDeCours/RetroPerceptron.pdf>
- [36] D.E. Rumelhart, G.E. Hinton, R.J. Williams, Learning representations by back-propagating errors, *Nature*. 323 (1986) 533–536. <https://doi.org/10.1038/323533a0>.
- [37] Soukeur EL Hussein Iz El Islam, et al. "Creating an artificial neural network time series model for the prediction of daily solar radiation in Oran." *DESALINATION AND WATER TREATMENT* 255 (2022): 163-171.

[38] Soukeur EL Hussein Iz El Islam. (2022). Réseaux de Neurones Artificiels Multi-Objectifs, [Thèse de doctorat, Université des Sciences et de la Technologie Houari Boumediene, BabEzzouar, Algérie]